Apuntes de Inferencia Estadística

Profesor: Nicolás Zalduendo

Universidad de Santiago de Chile

2026

Autor: *(Nicolás Aguilar)*

6 de abril de 2026

Índice

1. Tópicos en Probabilidad **2**
1.1. Espacios de trabajo . . . 2
1.2. Variable aleatoria y ley . . . 2
1.3. Función de distribución acumulada . . . 2
1.4. Esperanza . . . 3
1.5. Espacios L^p . . . 3
1.6. Covarianza y Varianza . . . 3
1.7. Leyes clásicas: . . . 4
1.8. Leyes absolutamente continuas . . . 4
1.9. Independencia . . . 5
1.10. Función característica . . . 9
1.11. Modos de convergencia . . . 11
1.12. Leyes de los grandes números . . . 12
1.13. Teorema Central del Límite . . . 14
1.14. Herramientas útiles para inferencia asintótica . . . 15

2. Copypaste de comandos **16**

3. Estimación Puntual **17**
3.1. Estimadores y sus propiedades . . . 17
3.1.1. Insesgamiento . . . 17
3.1.2. Error cuadrático medio . . . 18
3.1.3. Consistencia . . . 18
3.2. Métodos de estimación . . . 18
3.2.1. Método de los momentos . . . 18
3.2.2. Máxima verosimilitud . . . 18

4. Intervalos de Confianza **18**
4.1. Definición . . . 18
4.2. IC para la media con varianza conocida . . . 19
4.3. IC para la media con varianza desconocida . . . 19
4.4. IC para la varianza . . . 19

5. Pruebas de Hipótesis **19**
5.1. Formulación del problema . . . 19
5.2. Errores de tipo I y II . . . 20
5.3. Test de razón de verosimilitudes (TRV) . . . 20
5.4. p-valor . . . 20

1. Tópicos en Probabilidad

Para comprender la inferencia estadística, es fundamental contar con una base sólida en probabilidad. En esta sección se introducen los conceptos que establecerán el marco teórico del curso.

1.1. Espacios de trabajo

Sea $(\Omega, \mathcal{F}, P)$ un **espacio de probabilidad**, donde:

- Ω es el espacio muestral,
- $\mathcal{F}$ es una σ-álgebra de subconjuntos de Ω,
- P es una medida de probabilidad.

Consideraremos además un **espacio medible** $(\mathcal{E}, \mathcal{B}(\mathcal{E}))$, donde $\mathcal{E}$ es el espacio de valores y $\mathcal{B}(\mathcal{E})$ su σ-álgebra de Borel.

1.2. Variable aleatoria y ley

Definición 1.1 (Variable aleatoria)**.** Una variable aleatoria con valores en $\mathcal{E}$ es una función medible

$$X : \Omega \to \mathcal{E}.$$

La medibilidad significa que, para todo $A \in \mathcal{B}(\mathcal{E})$,

$$X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\} \in \mathcal{F}.$$

Definición 1.2 (Ley de una variable aleatoria)**.** La **ley** de X es la medida de probabilidad P_X sobre $\mathcal{E}$ definida por

$$P_X(A) = P(X^{-1}(A)), \quad \forall A \in \mathcal{B}(\mathcal{E}).$$

Equivalente y compactamente, se escribe

$$P_X = P \circ X^{-1},$$

y se conoce como la **medida imagen** (o *pushforward*) de P por X.

1.3. Función de distribución acumulada

Cuando $\mathcal{E} = \mathbb{R}$, la ley de X puede describirse mediante su función de distribución acumulada.

Definición 1.3 (Función de distribución acumulada (FDA))**.** La FDA de X es la función $F_X : \mathbb{R} \to [0, 1]$ definida por

$$\begin{aligned} F_X : \mathbb{R} &\to [0, 1] \\ x &\mapsto P(X \leq x) = P_X((-\infty, x]). \end{aligned}$$

La FDA determina completamente la ley de X, ya que permite reconstruir la medida P_X sobre la σ-álgebra de Borel.

1.4. Esperanza

Definición 1.4 (Esperanza)**.** Si X es integrable, su esperanza se define por

$$\mathbb{E}[X] = \int_\Omega X(\omega)\, dP(\omega).$$

Mediante el Teorema del Transporte, esta puede expresarse en términos de la ley de X:

$$\mathbb{E}[X] = \int_{\mathbb{R}} x\, dP_X(x).$$

1.5. Espacios L^p

Surge naturalmente la pregunta: *¿para qué variables aleatorias está bien definida la esperanza?*

Para responderla, introducimos los espacios L^p. Para $1 \leq p < \infty$, definimos

$$L^p(\Omega, \mathcal{F}, P) = \{X : \mathbb{E}[|X|^p] < \infty\}.$$

En particular:

- $X \in L^1$ si y solo si $\mathbb{E}[|X|] < \infty$,
- en este caso, la esperanza $\mathbb{E}[X]$ está bien definida.

Además, como P es una medida de probabilidad (finita), se tiene que

$$L^p \subseteq L^1 \quad \text{para todo } p \geq 1.$$

Sin embargo, la inclusión es estricta: existen variables en L^1 que no pertenecen a ningún L^p con $p > 1$.

Conclusión: el espacio natural donde la esperanza está bien definida es $L^1(\Omega, \mathcal{F}, P)$.

1.6. Covarianza y Varianza

Primero las definimos:

Definición 1.5 (Covarianza)**.** La covarianza entre dos variables aleatorias X e Y es definida por

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Definición 1.6 (Varianza)**.** La varianza de una variable aleatoria X es definida por

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Observación: la varianza es un caso particular de covarianza, ya que $\mathrm{Var}(X) = \mathrm{Cov}(X, X)$ y además si $X, Y \in L^2$ entonces $\langle X, Y \rangle_{L^2} = \mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

1.7. Leyes clásicas:

Distribuciones discretas ($\mathcal{E} = \mathbb{R}$):

- **Bernoulli:** $X \sim \text{Bern}(p)$ con $P(X = 1) = p$ y $P(X = 0) = 1 - p$. La ley es:
$$P_X = p\,\delta_1 + (1-p)\,\delta_0,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \int_{\mathbb{R}} x\,dP_X(x) = \int_{\mathbb{R}} x\,d(p\,\delta_1 + (1-p)\,\delta_0)(x) = p.$$
- **Binomial:** $X \sim \text{Bin}(n, p)$ con $n \in \mathbb{N}$ y $p \in [0, 1]$. La ley es:
$$P_X = \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k}\,\delta_k,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \sum_{k=0}^{n} k\,dP_X(k) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k} = np.$$
- **Poisson:** $X \sim \text{Poi}(\lambda)$ con $\lambda > 0$. La ley es:
$$P_X = \sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!}\,\delta_k,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k\,dP_X(k) = \sum_{k=0}^{\infty} k\,e^{-\lambda} \frac{\lambda^k}{k!} = \lambda.$$

1.8. Leyes absolutamente continuas

Hasta ahora hemos descrito leyes discretas mediante combinaciones de deltas de Dirac. Sin embargo, muchas variables aleatorias de interés toman valores en $\mathbb{R}$ de manera continua.

Sea λ la **medida de Lebesgue** en $\mathbb{R}$.

Definición 1.7 (Medida absolutamente continua)**.** Decimos que la ley P_X es **absolutamente continua** respecto de la medida de Lebesgue, y escribimos
$$P_X \ll \lambda,$$
si para todo conjunto boreliano A,
$$\lambda(A) = 0 \implies P_X(A) = 0.$$

Este concepto es fundamental, ya que permite introducir densidades.

Teorema 1.1 (Radon–Nikodym)**.** *Si $P_X \ll \lambda$, entonces existe una función medible $f_X : \mathbb{R} \to [0, \infty)$ tal que*
$$P_X(A) = \int_A f_X(x)\,dx, \quad \forall A \in \mathcal{B}(\mathbb{R}).$$

La función f_X se denomina **densidad** de X, y se escribe formalmente
$$P_X(dx) = f_X(x)\,dx.$$

Consecuencias

Si X admite densidad f_X, entonces:

- La probabilidad de un conjunto se calcula como

$$P(X \in A) = \int_A f_X(x)\,dx.$$

- La esperanza puede escribirse como

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x)\,dx.$$

Ejemplos clásicos

- **Uniforme:** $X \sim \mathcal{U}(a,b)$

$$f_X(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x)$$

- **Exponencial:** $X \sim \mathrm{Exp}(\lambda)$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{[0,\infty)}(x)$$

- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Interpretación: en el caso discreto, la ley se escribe como suma de deltas; en el caso continuo, como una densidad respecto a la medida de Lebesgue. Ambos enfoques son unificados mediante la noción de medida.

1.9. Independencia

La noción de independencia puede formularse tanto en términos de eventos como en términos de leyes.

Recordatorio: si $X : \Omega \to \mathcal{E}$ es una variable aleatoria, entonces X induce la σ-álgebra

$$\sigma(X) = \{X^{-1}(A) : A \in \mathcal{B}(\mathcal{E})\}.$$

En este sentido, la independencia de variables aleatorias puede entenderse como independencia entre las σ-álgebras que ellas generan.

Definición 1.8 (Variables aleatorias independientes)**.** Sean $X_1, \ldots, X_n$ variables aleatorias con valores en $\mathcal{E}$. Diremos que son **independientes** si para todo $B_1, \ldots, B_n \in \mathcal{B}(\mathcal{E})$ se tiene

$$P(X_1 \in B_1, \ldots, X_n \in B_n) = \prod_{i=1}^{n} P(X_i \in B_i).$$

Dicho de otra forma, la ley de la variable aleatoria vectorial

$$(X_1, \ldots, X_n) : \Omega \to \mathcal{E}^n$$

satisface

$$P_{(X_1,\ldots,X_n)} = P_{X_1} \otimes P_{X_2} \otimes \cdots \otimes P_{X_n}.$$

En efecto, para todo $B_1, \ldots, B_n \in \mathcal{B}(\mathcal{E})$,

$$P_{(X_1,\ldots,X_n)}(B_1 \times \cdots \times B_n) = P\big((X_1, \ldots, X_n) \in B_1 \times \cdots \times B_n\big),$$

y por definición de la variable aleatoria vectorial,

$$P\big((X_1, \ldots, X_n) \in B_1 \times \cdots \times B_n\big) = P(X_1 \in B_1, \ldots, X_n \in B_n).$$

Por otra parte,

$$(P_{X_1} \otimes \cdots \otimes P_{X_n})(B_1 \times \cdots \times B_n) = \prod_{i=1}^{n} P_{X_i}(B_i) = \prod_{i=1}^{n} P(X_i \in B_i).$$

Luego, la independencia equivale a que la ley conjunta coincida con el producto de las leyes marginales.

Observación: no debe confundirse independencia conjunta con independencia dos a dos.

Decimos que $X_1, \ldots, X_n$ son **independientes dos a dos** si para todo $i \neq j$, las variables X_i y X_j son independientes.

En general,

$$\text{independencia conjunta} \implies \text{independencia dos a dos},$$

pero el recíproco es falso.

Ejemplo

Sean X e Y variables aleatorias i.i.d. con ley Bernoulli(1/2) y definamos

$$Z = X + Y \quad (\text{mód } 2).$$

Entonces (X, Y, Z) son independientes dos a dos, pero no son independientes conjuntamente.

En efecto, existe una relación determinista entre ellas:

$$Z = X + Y \quad (\text{mód } 2).$$

Por tanto, conocer X e Y determina completamente a Z, lo que impide la independencia mutua.

Por ejemplo,

$$P(X = 0, Y = 0, Z = 1) = 0,$$

mientras que

$$P(X = 0)\, P(Y = 0)\, P(Z = 1) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}.$$

Como

$$0 \neq \frac{1}{8},$$

se concluye que X, Y y Z no son independientes.

Factorización de esperanzas

La independencia permite factorizar esperanzas de productos de funciones, como veremos a continuación:

Proposición: si $X_1, \ldots, X_n$ son independientes y $h_1, \ldots, h_n : \mathcal{E} \to \mathbb{R}$ son medibles y no negativas, entonces

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \prod_{i=1}^{n} \mathbb{E}[h_i(X_i)].$$

Más generalmente, la igualdad sigue siendo válida siempre que las cantidades involucradas estén bien definidas.

Demostración

Sea

$$H : \mathcal{E}^n \to \mathbb{R}$$

definida por

$$H(x_1, \ldots, x_n) = h_1(x_1)\, h_2(x_2) \cdots h_n(x_n).$$

Luego,

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \mathbb{E}\big(H(X_1, \ldots, X_n)\big).$$

Por el Teorema del Transporte,

$$\mathbb{E}\big(H(X_1, \ldots, X_n)\big) = \int_{\mathcal{E}^n} H(x_1, \ldots, x_n)\, dP_{(X_1,\ldots,X_n)}(x_1, \ldots, x_n).$$

Como $X_1, \ldots, X_n$ son independientes,

$$P_{(X_1,\ldots,X_n)} = P_{X_1} \otimes \cdots \otimes P_{X_n}.$$

Por lo tanto,

$$\int_{\mathcal{E}^n} H(x_1, \ldots, x_n)\, dP_{(X_1,\ldots,X_n)} = \int_{\mathcal{E}^n} h_1(x_1) \cdots h_n(x_n)\, d(P_{X_1} \otimes \cdots \otimes P_{X_n}).$$

Aplicando Tonelli–Fubini,

$$\int_{\mathcal{E}^n} h_1(x_1) \cdots h_n(x_n)\, d(P_{X_1} \otimes \cdots \otimes P_{X_n})$$

$$= \int_{\mathcal{E}} h_1(x_1)\, dP_{X_1}(x_1) \cdots \int_{\mathcal{E}} h_n(x_n)\, dP_{X_n}(x_n).$$

Finalmente, para cada i,

$$\int_{\mathcal{E}} h_i(x_i)\, dP_{X_i}(x_i) = \mathbb{E}[h_i(X_i)].$$

Así,

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \prod_{i=1}^{n} \mathbb{E}[h_i(X_i)].$$

□

Observación: el resultado sigue siendo válido si

$$\mathbb{E}[|h_i(X_i)|] < \infty, \qquad i = 1, \ldots, n.$$

En ese caso,

$$\mathbb{E}\left[\prod_{i=1}^{n} |h_i(X_i)|\right] = \prod_{i=1}^{n} \mathbb{E}[|h_i(X_i)|] < \infty,$$

por lo que el producto es integrable y puede aplicarse Fubini.

Corolario: si $X \perp Y$ y $X, Y \in L^2$, entonces

$$\mathrm{Cov}(X, Y) = 0.$$

Demostración: por independencia,

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Luego,

$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0.$$

□

Última observación: la recíproca es falsa en general:

$$\mathrm{Cov}(X, Y) = 0 \not\Longrightarrow X \perp Y.$$

Recordatorio

Recordemos que, si $X : \Omega \to \mathbb{R}$ es una variable aleatoria y $h : \mathbb{R} \to \mathbb{R}$ es medible, entonces

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx),$$

siempre que la integral esté bien definida.

(1) Caso absolutamente continuo. Si X es absolutamente continua, entonces existe una densidad f_X tal que

$$P_X(dx) = f_X(x)\, dx.$$

Luego,

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx) = \int_{\mathbb{R}} h(x) f_X(x)\, dx.$$

(2) Caso discreto. Si la ley de X es discreta, por ejemplo con soporte en $\mathbb{N}$, entonces

$$P_X(dx) = \sum_{k \in \mathbb{N}} P(X = k)\, \delta_k(dx).$$

Por lo tanto,

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx)$$

$$= \int_{\mathbb{R}} h(x) \left(\sum_{k \in \mathbb{N}} P(X = k)\, \delta_k(dx) \right).$$

Intercambiando suma e integral,

$$\mathbb{E}[h(X)] = \sum_{k\in\mathbb{N}} P(X=k) \int_{\mathbb{R}} h(x)\,\delta_k(dx).$$

Como

$$\int_{\mathbb{R}} h(x)\,\delta_k(dx) = h(k),$$

se obtiene

$$\mathbb{E}[h(X)] = \sum_{k\in\mathbb{N}} h(k)\,P(X=k).$$

1.10. Función característica

Sea X una variable aleatoria con valores en $\mathbb{R}^d$, es decir,

$$X = (X_1, \ldots, X_d).$$

La **función característica** de X es la función

$$\varphi_X : \mathbb{R}^d \to \mathbb{C}$$

definida por

$$\varphi_X(t) = \mathbb{E}\big(e^{i\langle t, X\rangle}\big), \qquad t \in \mathbb{R}^d.$$

Si $t = (t_1, \ldots, t_d)$, entonces

$$\langle t, X\rangle = \sum_{j=1}^{d} t_j X_j,$$

y por lo tanto

$$\varphi_X(t) = \mathbb{E}\left(\exp\left(i\sum_{j=1}^{d} t_j X_j\right)\right).$$

Observación: la función característica puede verse como una versión probabilística de la transformada de Fourier de la ley de X, pues

$$\varphi_X(t) = \int_{\mathbb{R}^d} e^{i\langle t,x\rangle}\,P_X(dx).$$

Casos particulares

Si X tiene densidad f_X en $\mathbb{R}^d$, entonces

$$\varphi_X(t) = \int_{\mathbb{R}^d} e^{i\langle t,x\rangle} f_X(x)\,dx.$$

Si X es discreta con valores $x_k \in \mathbb{R}^d$, entonces

$$\varphi_X(t) = \sum_k e^{i\langle t,x_k\rangle} P(X = x_k).$$

Observación

Si X es una variable aleatoria real, entonces su función característica viene dada por

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{\mathbb{R}} e^{itx}\, P_X(dx).$$

Si además X es absolutamente continua con densidad f_X, entonces

$$P_X(dx) = f_X(x)\, dx,$$

y por lo tanto

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx}\, P_X(dx) = \int_{\mathbb{R}} e^{itx} f_X(x)\, dx.$$

Ejemplos

(1) Si $X \sim \text{Bernoulli}(p)$, entonces

$$\varphi_X(t) = \mathbb{E}(e^{itX}).$$

Como X solo puede tomar los valores 0 y 1, se tiene

$$\varphi_X(t) = e^{it}\, P(X=1) + e^{i0t}\, P(X=0) = pe^{it} + (1-p).$$

Es decir,

$$\varphi_X(t) = (1-p) + pe^{it}.$$

(2) Si $Y \sim \text{Binomial}(N,p)$, entonces

Recordemos que una variable binomial puede escribirse como suma de variables Bernoulli i.i.d.:

$$Y = \sum_{j=1}^{N} Z_j, \qquad Z_j \overset{\text{i.i.d.}}{\sim} \text{Bernoulli}(p).$$

Luego,

$$\varphi_Y(t) = \mathbb{E}(e^{itY}) = \mathbb{E}\left(e^{it\sum_{j=1}^{N} Z_j}\right) = \mathbb{E}\left(\prod_{j=1}^{N} e^{itZ_j}\right).$$

Como las variables $Z_1, \ldots, Z_N$ son independientes, se obtiene

$$\varphi_Y(t) = \prod_{j=1}^{N} \mathbb{E}(e^{itZ_j}) = \prod_{j=1}^{N} \varphi_{Z_j}(t).$$

Como todas tienen la misma ley Bernoulli(p),

$$\varphi_Y(t) = \big(\varphi_{Z_1}(t)\big)^N = \big((1-p) + pe^{it}\big)^N.$$

Por tanto,

$$\varphi_Y(t) = \big((1-p) + pe^{it}\big)^N.$$

(3) Si $Z \sim \mathcal{N}(0,1)$, queremos calcular $\varphi_Z(t)$.

Más generalmente, si

$$W \sim \mathcal{N}(m, \sigma^2),$$

entonces puede escribirse como

$$W = m + \sigma Z, \qquad Z \sim \mathcal{N}(0,1).$$

Así,

$$\varphi_W(t) = \mathbb{E}(e^{itW}) = \mathbb{E}\big(e^{it(m+\sigma Z)}\big) = e^{imt}\mathbb{E}(e^{i\sigma t Z}).$$

Por definición de función característica,

$$\mathbb{E}(e^{i\sigma t Z}) = \varphi_Z(\sigma t).$$

Luego,

$$\varphi_W(t) = e^{imt}\varphi_Z(\sigma t).$$

Ahora bien, si $Z \sim \mathcal{N}(0,1)$, entonces

$$\varphi_Z(t) = e^{-t^2/2}.$$

Por consiguiente, si $W \sim \mathcal{N}(m, \sigma^2)$, se obtiene

$$\varphi_W(t) = e^{imt}\varphi_Z(\sigma t) = e^{imt}e^{-\sigma^2 t^2/2}.$$

Es decir,

$$\varphi_W(t) = \exp\left(imt - \frac{\sigma^2 t^2}{2}\right).$$

1.11. Modos de convergencia

Hasta ahora hemos estudiado variables aleatorias, sus leyes, independencia y función característica. El siguiente paso natural es comparar sucesiones de variables aleatorias y precisar en qué sentido una sucesión puede *converger*.

Sean $X, X_1, X_2, \ldots$ variables aleatorias reales definidas sobre un mismo espacio de probabilidad.

Definición 1.9 (Convergencia casi segura)**.** Decimos que X_n converge **casi seguramente** a X, y escribimos

$$X_n \xrightarrow{\text{c.s.}} X,$$

si

$$P\big(\{\omega \in \Omega : X_n(\omega) \to X(\omega)\}\big) = 1.$$

Definición 1.10 (Convergencia en probabilidad)**.** Decimos que X_n converge **en probabilidad** a X, y escribimos

$$X_n \xrightarrow{P} X,$$

si para todo $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \to 0.$$

Definición 1.11 (Convergencia en L^p)**.** Para $1 \le p < \infty$, decimos que X_n converge a X en L^p, y escribimos

$$X_n \xrightarrow{L^p} X,$$

si

$$\mathbb{E}[|X_n - X|^p] \to 0.$$

Definición 1.12 (Convergencia en distribución)**.** Decimos que X_n converge **en distribución** a X, y escribimos

$$X_n \xrightarrow{d} X,$$

si para todo punto de continuidad x de la FDA F_X,

$$F_{X_n}(x) \to F_X(x).$$

Relaciones entre los distintos modos de convergencia

Proposición:

$$X_n \xrightarrow{\text{c.s.}} X \quad \Longrightarrow \quad X_n \xrightarrow{P} X \quad \Longrightarrow \quad X_n \xrightarrow{d} X.$$

Además, para todo $p \geq 1$,

$$X_n \xrightarrow{L^p} X \quad \Longrightarrow \quad X_n \xrightarrow{P} X.$$

Observación: la recíproca de estas implicaciones es falsa en general.

Observación importante: si $c \in \mathbb{R}$ es una constante, entonces

$$X_n \xrightarrow{d} c \quad \Longleftrightarrow \quad X_n \xrightarrow{P} c.$$

Es decir, cuando el límite es determinista, convergencia en distribución y convergencia en probabilidad coinciden.

Criterio en términos de funciones características

La función característica permite estudiar convergencia en distribución de manera muy eficiente.

Teorema 1.2 (Teorema de continuidad de Lévy)**.** *Sean X_n y X variables aleatorias con valores en $\mathbb{R}^d$. Entonces*

$$X_n \xrightarrow{d} X$$

si y solo si

$$\varphi_{X_n}(t) \to \varphi_X(t), \qquad \forall t \in \mathbb{R}^d.$$

Este resultado será la herramienta fundamental para demostrar el Teorema Central del Límite.

1.12. Leyes de los grandes números

Sea $(X_n)_{n\geq 1}$ una sucesión de variables aleatorias i.i.d. con

$$\mu = \mathbb{E}[X_1].$$

Definimos el promedio muestral por

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

La intuición básica es que, al promediar muchas observaciones independientes con la misma ley, el promedio muestral debería acercarse al valor esperado.

Ley débil de los grandes números

Teorema 1.3 (Ley Débil de los Grandes Números). *Si $X_1, X_2, \ldots$ son i.i.d. y*

$$\mathbb{E}[X_1] = \mu, \qquad \mathrm{Var}(X_1) = \sigma^2 < \infty,$$

entonces

$$\overline{X}_n \xrightarrow{P} \mu.$$

Demostración

Como las variables son i.i.d., se tiene

$$\mathbb{E}[\overline{X}_n] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] = \mu.$$

Además, por independencia,

$$\mathrm{Var}(\overline{X}_n) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Luego, por la desigualdad de Chebyshev, para todo $\varepsilon > 0$,

$$P(|\overline{X}_n - \mu| > \varepsilon) \leq \frac{\mathrm{Var}(\overline{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \to 0.$$

Por lo tanto,

$$\overline{X}_n \xrightarrow{P} \mu.$$

□

Ley fuerte de los grandes números

Teorema 1.4 (Ley Fuerte de los Grandes Números). *Si $X_1, X_2, \ldots$ son i.i.d. y*

$$\mathbb{E}[|X_1|] < \infty,$$

entonces

$$\overline{X}_n \xrightarrow{\text{c.s.}} \mu, \qquad \mu = \mathbb{E}[X_1].$$

Observación: la ley fuerte es más fuerte que la ley débil, pues la convergencia casi segura implica convergencia en probabilidad.

Interpretación estadística

Si $X_1, \ldots, X_n$ representan observaciones de una misma población, entonces la ley de los grandes números justifica que el promedio muestral

$$\overline{X}_n$$

sea un buen estimador de la media poblacional

$$\mu = \mathbb{E}[X_1].$$

Por ejemplo, si $X_i \sim \text{Bernoulli}(p)$ i.i.d., entonces

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

es la proporción muestral de éxitos, y la ley de los grandes números afirma que

$$\overline{X}_n \xrightarrow{P} p \qquad \text{e incluso} \qquad \overline{X}_n \xrightarrow{\text{c.s.}} p.$$

1.13. Teorema Central del Límite

La ley de los grandes números describe el comportamiento del promedio muestral *sin escala*. El siguiente problema natural es entender las fluctuaciones de $\overline{X}_n$ alrededor de μ a una escala adecuada.

Teorema 1.5 (Teorema Central del Límite de Lindeberg–Lévy)**.** *Si $X_1, X_2, \ldots$ son i.i.d. con*

$$\mathbb{E}[X_1] = \mu, \qquad \text{Var}(X_1) = \sigma^2 \in (0, \infty),$$

entonces

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1).$$

Equivalentemente,

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0,1).$$

Idea de la demostración mediante funciones características

Definimos

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

Entonces $Y_1, Y_2, \ldots$ son i.i.d. y satisfacen

$$\mathbb{E}[Y_1] = 0, \qquad \text{Var}(Y_1) = 1.$$

Sea

$$S_n = \frac{1}{\sqrt{n}}\sum_{i=1}^{n} Y_i.$$

Basta demostrar que

$$S_n \xrightarrow{d} \mathcal{N}(0,1).$$

Como las Y_i son independientes,

$$\varphi_{S_n}(t) = \mathbb{E}\left(e^{itS_n}\right) = \mathbb{E}\left(e^{it\frac{1}{\sqrt{n}}\sum_{i=1}^{n} Y_i}\right) = \mathbb{E}\left(\prod_{i=1}^{n} e^{i\frac{t}{\sqrt{n}}Y_i}\right).$$

Usando independencia,

$$\varphi_{S_n}(t) = \prod_{i=1}^{n} \mathbb{E}\left(e^{i\frac{t}{\sqrt{n}}Y_i}\right) = \left(\varphi_{Y_1}\left(\frac{t}{\sqrt{n}}\right)\right)^n.$$

Ahora bien, como $\mathbb{E}[Y_1] = 0$ y $\mathbb{E}[Y_1^2] = 1$, se tiene el desarrollo alrededor de 0:

$$\varphi_{Y_1}(u) = 1 - \frac{u^2}{2} + o(u^2), \qquad u \to 0.$$

Tomando

$$u = \frac{t}{\sqrt{n}},$$

obtenemos

$$\varphi_{Y_1}\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

Por tanto,

$$\varphi_{S_n}(t) = \left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n \to e^{-t^2/2}.$$

Pero

$$e^{-t^2/2}$$

es la función característica de una variable $\mathcal{N}(0,1)$. Luego, por el Teorema de continuidad de Lévy,

$$S_n \xrightarrow{d} \mathcal{N}(0,1).$$

Interpretación

El TCL afirma que, para n grande,

$$\overline{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Más precisamente, la cantidad

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma}$$

se comporta aproximadamente como una normal estándar cuando n es grande.

Esta aproximación es una de las bases de la inferencia estadística clásica.

1.14. Herramientas útiles para inferencia asintótica

Teorema de mapeo continuo

Teorema 1.6 (Teorema de mapeo continuo)**.** *Si*

$$X_n \xrightarrow{d} X$$

y $g : \mathbb{R} \to \mathbb{R}$ *es continua, entonces*

$$g(X_n) \xrightarrow{d} g(X).$$

Observación: este resultado permite transportar convergencia en distribución a través de funciones continuas.

Teorema de Slutsky

Teorema 1.7 (Teorema de Slutsky)**.** *Si*

$$X_n \xrightarrow{d} X \qquad y \qquad Y_n \xrightarrow{P} c,$$

donde c es una constante, entonces:

$$X_n + Y_n \xrightarrow{d} X + c,$$

$$X_n Y_n \xrightarrow{d} cX,$$

y, si $c \neq 0$,

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

Aplicación típica

Supongamos que

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0,1),$$

y además que S_n es un estimador tal que

$$S_n \xrightarrow{P} \sigma.$$

Entonces, por Slutsky,

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{S_n} \xrightarrow{d} \mathcal{N}(0,1).$$

Este tipo de resultado aparece constantemente en inferencia estadística, cuando se reemplaza un parámetro desconocido por un estimador consistente.

2. Copypaste de comandos

```
\section{Título de la sección}              -> Crea una sección principal.

\subsection{Título de la subsección}        -> Crea una subsección dentro de una secci

\textbf{texto en negrita}                   -> Pone el texto en negrita.

\emph{texto en énfasis}                     -> Da énfasis (normalmente cursiva).

\begin{defi}[Nombre de la definición]
  Texto de la definición.
\end{defi}
-> Entorno para escribir una definición.

\begin{teo}[Nombre del teorema]
  Texto del teorema.
\end{teo}
-> Entorno para enunciar un teorema.
```

```
\begin{obs}
  Texto de la observación.
\end{obs}
-> Entorno para agregar una observación o comentario.

\begin{enumerate}
  \item Primer ítem.
  \item Segundo ítem.
\end{enumerate}
-> Lista numerada; cada \item agrega un elemento.

$X_1, X_2, \ldots, X_n \iid f(\cdot\,;\theta)$   -> Notación de muestra i.i.d. con dis

$\E[X]$                                          -> Valor esperado de X.

$\bar{X}_n$                                      -> Media muestral.

$\hat{\theta}$                                  -> Estimador de theta.

$\sigma^2$                                       -> Varianza poblacional.

$\theta \in \Theta$                             -> El parámetro theta pertenece al espaci

\[
  \bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i
\]
-> Fórmula de la media muestral usando suma.

\[
  \bar{X}_n \xrightarrow{\text{c.s.}} \mu
\]
-> Convergencia casi segura de la media muestral hacia mu.
```

3. Estimación Puntual

3.1. Estimadores y sus propiedades

Definición 3.1 (Estimador)**.** Un **estimador** de θ es un estadístico $\hat{\theta} = \hat{\theta}(X_1, \ldots, X_n)$ cuyo valor se toma como aproximación del parámetro desconocido θ.

3.1.1. Insesgamiento

Definición 3.2 (Estimador insesgado)**.** $\hat{\theta}$ es **insesgado** (o no sesgado) para θ si

$$\mathbb{E}_\theta[\hat{\theta}] = \theta \quad \forall\, \theta \in \Theta.$$

El **sesgo** se define como $\text{Sesgo}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$.

Ejemplo 3.1. Si $X_1, \ldots, X_n \overset{\text{iid}}{\sim} (\mu, \sigma^2)$, entonces $\bar{X}$ es insesgado para μ y $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ es insesgado para σ^2.

3.1.2. Error cuadrático medio

Definición 3.3 (ECM)**.** El **error cuadrático medio** de $\hat{\theta}$ es

$$\mathrm{ECM}(\hat{\theta}) = \mathbb{E}\big[(\hat{\theta} - \theta)^2\big] = \mathrm{Var}(\hat{\theta}) + [\mathrm{Sesgo}(\hat{\theta})]^2.$$

3.1.3. Consistencia

Definición 3.4 (Consistencia)**.** $\hat{\theta}_n$ es **consistente** para θ si $\hat{\theta}_n \xrightarrow{P} \theta$, es decir,

$$\forall\, \varepsilon > 0: \quad P_\theta(|\hat{\theta}_n - \theta| > \varepsilon) \to 0 \quad \text{cuando } n \to \infty.$$

Resultado importante

Si $\mathrm{ECM}(\hat{\theta}_n) \to 0$ cuando $n \to \infty$, entonces $\hat{\theta}_n$ es consistente para θ.

3.2. Métodos de estimación

3.2.1. Método de los momentos

Igualar los k primeros momentos poblacionales con los k primeros momentos muestrales y resolver el sistema de ecuaciones resultante en θ.

3.2.2. Máxima verosimilitud

Definición 3.5 (Función de verosimilitud)**.** Dada una muestra observada $\mathbf{x} = (x_1, \ldots, x_n)$, la **función de verosimilitud** es

$$L(\theta; \mathbf{x}) = \prod_{i=1}^{n} f(x_i; \theta), \quad \theta \in \Theta.$$

El **estimador de máxima verosimilitud (EMV)** es $\hat{\theta}_{\mathrm{MLE}} = \arg\max_\theta L(\theta; \mathbf{x})$.

Observación. Normalmente se trabaja con la *log-verosimilitud* $\ell(\theta) = \log L(\theta)$ por conveniencia numérica.

Teorema 3.1 (Propiedades asintóticas del EMV)**.** *Bajo condiciones de regularidad, si $n \to \infty$:*

$$\sqrt{n}(\hat{\theta}_{MLE} - \theta) \xrightarrow{d} \mathcal{N}\big(0,\, [I(\theta)]^{-1}\big),$$

*donde $I(\theta)$ es la **información de Fisher** de una observación.*

4. Intervalos de Confianza

4.1. Definición

Definición 4.1 (Intervalo de confianza)**.** Un **intervalo de confianza** al nivel $(1-\alpha)$ para θ es un intervalo aleatorio $[L(\mathbf{X}),\, U(\mathbf{X})]$ tal que

$$P_\theta\big(L(\mathbf{X}) \le \theta \le U(\mathbf{X})\big) \ge 1 - \alpha \quad \forall\, \theta \in \Theta.$$

¡Cuidado!

El intervalo es *aleatorio*, no el parámetro. Una vez observada la muestra, el intervalo calculado $[l, u]$ o contiene a θ o no lo contiene; no tiene sentido hablar de probabilidad en ese caso.

4.2. IC para la media con varianza conocida

Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$ con σ^2 conocida. Entonces

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1),$$

y el IC al $(1 - \alpha)$ para μ es

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}},$$

donde $z_{\alpha/2}$ es el cuantil $1 - \alpha/2$ de la $\mathcal{N}(0, 1)$.

4.3. IC para la media con varianza desconocida

Cuando σ^2 es desconocida, se reemplaza por S^2 y se usa la distribución t de Student:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

El IC al $(1 - \alpha)$ para μ es

$$\bar{X} \pm t_{n-1,\,\alpha/2} \frac{S}{\sqrt{n}}.$$

4.4. IC para la varianza

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1} \implies IC_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)S^2}{\chi^2_{n-1,\,\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{n-1,\,1-\alpha/2}} \right].$$

5. Pruebas de Hipótesis

5.1. Formulación del problema

Definición 5.1 (Hipótesis estadística)**.** Una **hipótesis estadística** es una afirmación sobre el parámetro θ (o sobre la distribución de los datos).

- H_0: hipótesis nula (afirmación que se desea refutar).
- H_1 (o H_a): hipótesis alternativa.

5.2. Errores de tipo I y II

	H_0 verdadera	H_0 falsa
No rechazar H_0	Decisión correcta	Error tipo II (β)
Rechazar H_0	Error tipo I (α)	Decisión correcta

Definición 5.2 (Nivel de significación)**.** $\alpha = P(\text{rechazar } H_0 \mid H_0 \text{ verdadera})$. Valores típicos: 0,01, 0,05, 0,10.

Definición 5.3 (Potencia)**.** $\pi(\theta) = P(\text{rechazar } H_0 \mid \theta)$. Para $\theta \in H_1$ se desea que $\pi(\theta)$ sea grande.

5.3. Test de razón de verosimilitudes (TRV)

Definición 5.4 (Estadístico TRV)**.**

$$\Lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta; \mathbf{x})}{\sup_{\theta \in \Theta} L(\theta; \mathbf{x})}.$$

Se rechaza H_0 cuando $\Lambda(\mathbf{x}) \leq c$ para algún umbral c.

Teorema 5.1 (Wilks)**.** *Bajo condiciones de regularidad y si H_0 es verdadera,*

$$-2 \log \Lambda(\mathbf{X}) \xrightarrow{d} \chi^2_r,$$

donde $r = \dim(\Theta) - \dim(\Theta_0)$.

5.4. p-valor

Definición 5.5 (p-valor)**.** El p-valor es la probabilidad, bajo H_0, de observar un estadístico de prueba tan extremo o más que el observado:

$$p = P_{H_0}(T(\mathbf{X}) \geq T(\mathbf{x}_{\text{obs}})).$$

Se rechaza H_0 si $p \leq \alpha$.

Resultado importante

Interpretación: un p-valor pequeño es evidencia en contra de H_0. No mide la probabilidad de que H_0 sea verdadera.